

**Predicción de escalamiento en interacciones de servicio al cliente
mediante modelos de clasificación y un dashboard interactivo**

Luis José Rivas Bernal

Programación para ciencias de datos II

Docente: William Eduardo Clavijo Bohorquez

FUNDACIÓN UNIVERSITARIA COMPENSAR.

CIENCIA DE DATOS

Septiembre, 24 de 2026

Capítulo I

Introducción

En los entornos de servicio al cliente, las interacciones pueden presentar diferentes niveles de complejidad y, en algunos casos, requieren ser escaladas a niveles superiores de soporte. Identificar los factores relacionados con estos escalamientos puede aportar información útil para comprender el comportamiento de la operación y apoyar futuras estrategias de atención.

El presente proyecto desarrolla un proceso de análisis y modelado orientado a estimar la probabilidad de escalamiento de una interacción de servicio al cliente. Para ello, se trabaja con un conjunto de datos compuesto por 10.000 interacciones que incluye información relacionada con el canal de atención, tipo de cliente, tipo de solicitud, resolución en el primer contacto, satisfacción del cliente, tiempo promedio de atención, sentimiento y otros indicadores operativos.

El desarrollo parte de modelos sencillos y avanza mediante diferentes etapas de mejora, incluyendo incorporación de nuevas variables, estandarización, codificación de variables categóricas, balanceo de clases, transformación logarítmica y optimización de hiperparámetros. Adicionalmente, se compara el desempeño de modelos de regresión logística con un modelo de bosque aleatorio para evaluar si las relaciones no lineales permiten mejorar la capacidad de clasificación.

Los resultados obtenidos se presentan finalmente mediante un dashboard interactivo desarrollado con Dash y Plotly. Este permite explorar indicadores operativos, comparar el desempeño de los modelos, modificar el umbral de clasificación y analizar las variables asociadas con las predicciones. La guía del proyecto establece precisamente que el flujo debe

mantener coherencia entre el problema, los datos, el entrenamiento, los archivos de resultados y el dashboard final.

Objetivos

Objetivo general

Desarrollar y evaluar modelos de clasificación para estimar la probabilidad de escalamiento de interacciones de servicio al cliente y presentar sus principales resultados mediante un dashboard interactivo.

Objetivos Específicos

1. Analizar las características principales del conjunto de datos y la distribución de la variable objetivo.
2. Construir un modelo de referencia que permita establecer una línea base de comparación.
3. Incorporar nuevas variables y técnicas de preprocesamiento para mejorar el proceso de modelado.
4. Evaluar estrategias de balanceo de clases y transformación de variables.
5. Optimizar hiperparámetros mediante validación cruzada.
6. Comparar el desempeño de modelos de regresión logística y bosque aleatorio utilizando diferentes métricas de clasificación.
7. Analizar la importancia de las variables dentro del modelo seleccionado.

8. Diseñar un dashboard interactivo que permita explorar los resultados del proyecto mediante filtros, indicadores, gráficos y modificación del umbral de clasificación.

Capítulo II

Planteamiento del problema y descripción de los datos

Planteamiento del problema

En las operaciones de servicio al cliente, no todas las interacciones tienen el mismo nivel de complejidad. Algunas pueden resolverse durante el primer contacto, mientras que otras requieren ser escaladas a niveles superiores de soporte. Este tipo de escalamiento puede estar relacionado con diferentes factores operativos, como el canal de atención, el tipo de cliente, la naturaleza de la solicitud, el tiempo de atención o la percepción del cliente durante la interacción.

A partir de esta situación, el proyecto busca analizar si las variables disponibles permiten identificar patrones asociados con el escalamiento de una interacción. Para ello, se plantea un problema de clasificación binaria en el que se intenta predecir si una interacción será escalada o no. Para este caso, la variable objetivo es “escalated”, en donde cero representa una interacción no escalada y uno representa una interacción escalada.

La pregunta principal que orienta el proyecto es:

¿Es posible estimar la probabilidad de escalamiento de una interacción de servicio al cliente a partir de variables operativas y características de la interacción?

Descripción del conjunto de datos

El conjunto de datos utilizado contiene 10.000 registros, donde cada fila representa una interacción individual de servicio al cliente. Este dataset incluye información operativa, características del cliente y variables asociadas con el desarrollo de la interacción. También hay que tener en cuenta que durante la revisión inicial del dataset no se identificaron valores nulos ni registros duplicados, por lo que la información pudo utilizarse directamente para el análisis exploratorio y las etapas posteriores de modelado.

Las principales variables son:

Variable	Descripción
interaction_id	Identificador único de la interacción.
date	Fecha de la interacción.
time	Hora de la interacción.
agent_id	Identificador del agente.
channel	Canal de atención utilizado.
client_type	Tipo de cliente.
issue_type	Tipo de solicitud o problema reportado.
fcr	Indica si la interacción fue resuelta en el primer contacto.
csat_score	Nivel de satisfacción del cliente.
aht_seconds	Duración de la interacción en segundos.
escalated	Variable objetivo que indica si la interacción fue escalada.
ad_spend_recovered	Valor monetario recuperado asociado con la interacción.
sentiment	Sentimiento identificado durante la interacción.

Distribución de la variable objetivo y variables seleccionadas

La variable `escalated` presenta un desbalance entre las dos clases, el 80.2% de las interacciones corresponden a casos no escalados, mientras que el 19.8 % corresponden a casos escalados. Esta distribución es importante porque puede afectar la interpretación de métricas como el accuracy.

Un modelo podría obtener una exactitud relativamente alta simplemente prediciendo la clase mayoritaria, sin identificar correctamente las interacciones escaladas. Por esta razón, durante el proyecto no se utilizó únicamente el accuracy para evaluar los modelos. Otras métricas que se tuvieron en consideración fueron el recall, F1-score y ROC-AUC.

Para el desarrollo de los modelos se utilizaron variables numéricas y categóricas relacionadas con la interacción.

Entre las variables numéricas se incluyeron:

- `aht_seconds`
- `csat_score`
- `fcr`
- `ad_spend_recovered`

Entre las variables categóricas se utilizaron:

- channel
- client_type
- issue_type
- sentiment

También se creó una variable transformada:

$$ad_spend_log = \log(1 + ad_spend_recovered)$$

Esta transformación se incorporó como parte del proceso de mejora del modelo, con el objetivo de reducir el efecto de valores altos y evaluar si una representación diferente de la variable monetaria podía aportar información adicional.

Consideraciones iniciales

El objetivo del proyecto no fue únicamente obtener el modelo con mayor resultado numérico, sino evaluar de forma progresiva diferentes alternativas y determinar si los datos disponibles contienen suficiente información para realizar una clasificación confiable.

Debido al desbalance de clases y a los resultados obtenidos en etapas anteriores, fue necesario probar diferentes estrategias de preprocesamiento, balanceo y ajuste de modelos. Esto

permitió comparar de forma más completa el comportamiento de distintas configuraciones antes de seleccionar el modelo final.

Capítulo III

Metodología y preparación de los datos

Preparación y preprocesamiento de los datos

Para el desarrollo del proyecto se utilizó un enfoque de clasificación binaria, tomando como variable objetivo escalated. El objetivo fue estimar la probabilidad de que una interacción de servicio al cliente fuera escalada a partir de diferentes características operativas.

Antes del entrenamiento de los modelos, el conjunto de datos fue dividido en datos de entrenamiento y prueba utilizando una separación estratificada. Esto permitió conservar una proporción similar de casos escalados y no escalados en ambos subconjuntos, evitando que el desbalance original de la variable objetivo se concentrara únicamente en una de las particiones.

Dentro del conjunto de variables se trabajó con características numéricas como aht_seconds, csat_score, fcr y ad_spend_recovered, así como con variables categóricas como channel, client_type, issue_type y sentiment.

Para las variables numéricas se utilizó estandarización mediante StandardScaler, mientras que las categóricas fueron transformadas con codificación One-Hot. Todo este proceso se integró dentro de un pipeline, de manera que el mismo tratamiento aplicado durante el entrenamiento pudiera mantenerse al momento de realizar predicciones.

Este tipo de estructura también ayuda a reducir errores asociados con aplicar transformaciones de forma separada. La guía del profesor señala precisamente que el preprocesamiento debe mantenerse dentro del pipeline para que el mismo proceso se utilice

durante entrenamiento y predicción. Como parte de las mejoras sugeridas durante el curso, también se aplicó una transformación logarítmica sobre `ad_spend_recovered`, para esto se utiliza:

$$ad_spend_log = \log(1 + ad_spend_recovered)$$

Esta transformación se probó con el objetivo de reducir el efecto de valores altos y evaluar si una distribución diferente de esta variable podía aportar mayor capacidad explicativa al modelo.

```
variables_numericas = [  
    "aht_seconds",  
    "csat_score",  
    "fcr",  
    "ad_spend_recovered"  
]  
  
variables_categoricas = [  
    "channel",  
    "client_type",  
    "issue_type",  
    "sentiment"  
]  
  
X_multi = df[  
    variables_numericas + variables_categoricas  
]  
  
y = df["escalated"]
```

```

preprocesador = ColumnTransformer(
    transformers=[
        (
            "num",
            StandardScaler(),
            variables_numericas
        ),
        (
            "cat",
            OneHotEncoder(
                handle_unknown="ignore"
            ),
            variables_categoricas
        )
    ]
)

```

Figura 3. Configuración de variables y proceso de preprocesamiento utilizado en el modelo.

Estrategia de modelado y evaluación

El proceso de modelado se desarrolló de forma progresiva, comenzando con una regresión logística sencilla y agregando posteriormente nuevas variables y técnicas de mejora. Esta estrategia permitió observar cómo cambiaba el desempeño del modelo en cada etapa y determinar si las modificaciones realmente aportaban alguna mejora.

Debido al desbalance de la variable objetivo, se probó el parámetro `class_weight="balanced"` en la regresión logística. Esta configuración permitió que la clase

minoritaria tuviera mayor peso durante el entrenamiento, evitando que el modelo se limitara a predecir únicamente la clase mayoritaria.

También se realizó una búsqueda de hiperparámetros mediante GridSearchCV, evaluando diferentes valores de regularización y configuraciones del modelo. La validación cruzada se realizó sobre los datos de entrenamiento para comparar distintas combinaciones antes de evaluar el modelo final sobre el conjunto de prueba.

Además de la regresión logística, se incorporó un modelo de Random Forest con el objetivo de explorar relaciones no lineales entre las variables. La guía avanzada del proyecto propone precisamente una secuencia de comparación entre una línea base, una regresión logística regularizada y un bosque aleatorio, utilizando validación cruzada para el ajuste de hiperparámetros.

Para evaluar el desempeño se utilizaron las métricas accuracy, precision, recall, F1-score y ROC-AUC. La accuracy no se tomó como único criterio, ya que el desbalance entre clases podía generar valores aparentemente altos incluso si el modelo no detectaba correctamente los casos escalados. La guía también advierte que esta métrica puede resultar engañosa en escenarios con clases desbalanceadas.

```
parametros = {  
    "modelo__C": [0.01, 0.1, 1, 10, 100],  
    "modelo__solver": ["lbfgs", "liblinear", "saga"]  
}  
  
busqueda = GridSearchCV(  
    estimator=pipeline_busqueda,  
    param_grid=parametros,  
    scoring="f1",  
    cv=5,  
    n_jobs=-1  
)
```

Figura 4. Configuración de la búsqueda de hiperparámetros mediante GridSearchCV.

Capítulo IV

Desarrollo e iteración de los modelos

Evolución de los modelos

El proceso de modelado se desarrolló de forma progresiva. La idea fue partir de una configuración sencilla y agregar cambios de manera controlada para identificar si cada ajuste generaba una mejora real en la capacidad de clasificación.

El primer modelo utilizó únicamente `aht_seconds` como predictor. Aunque obtuvo una accuracy cercana al 80 %, presentó precision, recall y F1 iguales a cero para la clase escalada. Esto evidenció que el modelo estaba clasificando prácticamente todos los casos como no escalados y que la accuracy, por sí sola, no era suficiente para evaluar su desempeño.

Posteriormente se construyó un modelo multivariable incorporando variables numéricas y categóricas. Este cambio permitió ampliar la información disponible para el modelo, aunque los resultados continuaron mostrando una capacidad limitada para identificar escalaciones.

Debido al desbalance de clases, se incorporó el parámetro `class_weight="balanced"`. Con este ajuste, el modelo comenzó a detectar una mayor cantidad de interacciones escaladas. Aunque la accuracy disminuyó, el recall y el F1-score mejoraron, lo que mostró que el modelo ya no se limitaba a predecir únicamente la clase mayoritaria. También se evaluó una transformación logarítmica sobre `ad_spend_recovered`. Esta modificación produjo una mejora marginal en recall y F1, pero no generó un incremento relevante en ROC-AUC. Esto permitió

concluir que la transformación ayudaba ligeramente en la clasificación, pero no resolvía el problema principal de separación entre clases.

Como siguiente etapa se realizó una optimización de hiperparámetros mediante GridSearchCV. Se probaron diferentes valores de regularización y configuraciones de solver para la regresión logística. Los resultados obtenidos fueron muy similares entre las diferentes combinaciones, lo que indicó que el desempeño del modelo estaba más limitado por la señal contenida en los datos que por la configuración específica del algoritmo.

	param_modelo_C	param_modelo_solver	mean_test_score
3	0.10	lbfgs	0.291185
4	0.10	liblinear	0.290895
5	0.10	saga	0.290836
2	0.01	saga	0.290533
1	0.01	liblinear	0.290491
10	10.00	liblinear	0.290195
11	10.00	saga	0.290195
13	100.00	liblinear	0.290195
7	1.00	liblinear	0.290137
8	1.00	saga	0.290137
14	100.00	saga	0.290133
6	1.00	lbfgs	0.289952
0	0.01	lbfgs	0.289750
9	10.00	lbfgs	0.289591
12	100.00	lbfgs	0.289591

Figura 5. Resultados de la búsqueda de hiperparámetros para la regresión logística.

Comparación con un modelo no lineal

Como parte de la etapa final de mejora, se incorporó un modelo de Random Forest. La intención fue evaluar si un algoritmo capaz de capturar relaciones no lineales podía superar el desempeño de la regresión logística.

El bosque aleatorio fue ajustado mediante validación cruzada, probando diferentes configuraciones de profundidad, número de árboles, tamaño mínimo de hoja y balanceo de clases. La guía avanzada del proyecto propone precisamente este tipo de comparación entre una línea base, una regresión logística regularizada y un bosque aleatorio.

El Random Forest obtuvo el mayor ROC-AUC entre los modelos evaluados, con un valor aproximado de 0.513. Sin embargo, este resultado se encuentra muy próximo a 0.50, por lo que la capacidad del modelo para separar casos escalados y no escalados sigue siendo limitada.

Además, con un umbral de 0.50, el bosque aleatorio no identificó correctamente casos positivos, lo que produjo valores de precision, recall y F1 iguales a cero. Esto confirmó que, aunque el modelo obtuvo el mayor ROC-AUC, su utilidad práctica sigue siendo reducida.

La regresión logística regularizada, por otro lado, presentó un comportamiento diferente: obtuvo un recall aproximado de 0.55 y un F1 cercano a 0.30, lo que muestra que era capaz de detectar una mayor proporción de escalaciones, aunque a costa de generar más falsos positivos.

	version	roc_auc_prueba	accuracy	precision	recall	f1
0	3. Bosque ajustado	0.513143	0.8016	0.000000	0.000000	0.000000
1	2. Logistica regularizada	0.506938	0.4976	0.208589	0.548387	0.302222
2	1. Linea base	0.475028	0.8016	0.000000	0.000000	0.000000

Figura 6. Comparación de métricas de desempeño entre los modelos evaluados.

Selección del modelo

A partir de los resultados obtenidos, el bosque aleatorio fue seleccionado como modelo con mayor ROC-AUC dentro del pipeline avanzado. Sin embargo, esta selección no implica que el modelo presente un desempeño alto.

El valor obtenido indica que la separación entre las dos clases es débil y que las probabilidades estimadas para interacciones escaladas y no escaladas presentan un alto nivel de solapamiento.

Por esta razón, el modelo se utilizó principalmente con fines exploratorios dentro del dashboard. Su propósito es permitir analizar el comportamiento de las predicciones, comparar métricas y observar cómo cambia la clasificación al modificar el umbral, sin asumir que las predicciones son suficientemente confiables para automatizar decisiones operativas.

Capítulo V

Evaluación y comparación de resultados

Análisis de las métricas obtenidas

La comparación de los modelos permitió observar que el desempeño varió de acuerdo con la métrica utilizada. La línea base presentó una accuracy cercana al 80 %, pero precision, recall y F1 iguales a cero para la clase escalada. Esto confirmó que el modelo estaba favoreciendo la clase mayoritaria y que una accuracy alta no necesariamente representa una buena capacidad de clasificación cuando existe desbalance entre clases.

La regresión logística regularizada mostró un comportamiento diferente. Su accuracy disminuyó aproximadamente al 49.8 %, pero logró un recall cercano a 0.55 y un F1 alrededor de 0.30. Esto significa que el modelo fue capaz de identificar una mayor proporción de las interacciones realmente escaladas, aunque también aumentó la cantidad de falsos positivos.

El modelo de Random Forest obtuvo el mayor ROC-AUC, con un valor aproximado de 0.513. Sin embargo, este resultado continúa siendo muy cercano a 0.50, lo que indica una capacidad limitada para diferenciar correctamente entre casos escalados y no escalados. La guía utilizada para el proyecto también señala que el ROC-AUC permite evaluar la capacidad del modelo para ordenar positivos por encima de negativos, mientras que la accuracy puede resultar engañosa cuando existe desbalance entre clases.

En términos generales, los resultados indican que ninguno de los modelos evaluados logró una separación clara entre las dos clases. Aunque el bosque aleatorio obtuvo el mayor

ROC-AUC, la regresión logística regularizada presentó mejores resultados en recall y F1 para la clase positiva.

Matriz de confusión y distribución de probabilidades

La evaluación del modelo seleccionado mostró que las probabilidades estimadas se concentran principalmente alrededor de 0.20. En el conjunto de prueba, la probabilidad media de escalamiento fue aproximadamente 0.199 y la mayoría de los valores se ubicó en un intervalo muy reducido.

Al comparar los casos escalados y no escalados, se observó que ambas distribuciones eran muy similares. La probabilidad promedio para los casos no escalados fue cercana a 0.1991, mientras que para los escalados fue aproximadamente 0.1993. Esta diferencia mínima confirma que el modelo tiene dificultades para separar ambos grupos.

Este comportamiento también explica por qué un umbral fijo de 0.50 resulta poco útil para este modelo. Prácticamente ninguna observación alcanza ese valor, por lo que el modelo termina clasificando casi todos los registros como no escalados.

Por esta razón, en el dashboard se incorporó un umbral interactivo. Modificar este valor permite analizar cómo cambia la cantidad de casos clasificados como positivos, así como las métricas y la matriz de confusión. Sin embargo, cambiar el umbral no modifica ni vuelve a entrenar el modelo; únicamente cambia la forma en que las probabilidades estimadas se convierten en clases.

Matriz de confusión




Figura 7. Matriz de confusión del modelo utilizando un umbral de clasificación de 0.20.

Distribución de probabilidades estimadas




Figura 8. Distribución de las probabilidades estimadas según la clase real.

Capítulo VI

Desarrollo del dashboard interactivo

Construcción y adaptación del dashboard

Como etapa final del proyecto, se desarrolló un dashboard interactivo utilizando Dash y Plotly. El propósito fue presentar los resultados del modelado de una forma más clara y facilitar la exploración de la información mediante filtros, indicadores y visualizaciones.

La plantilla original estaba orientada a un caso de deserción académica, por lo que fue necesario adaptar su estructura al contexto de servicio al cliente. Para ello, se modificaron los nombres de las variables, los filtros, los indicadores, las visualizaciones y la narrativa del tablero, manteniendo la lógica general del proyecto. La guía del profesor recomienda precisamente realizar esta adaptación de forma incremental, empezando por las rutas de datos, luego los filtros, KPI, visualizaciones, métricas, tabla y narrativa.

El dashboard final permite filtrar la información por channel, client_type, issue_type y sentiment. También incluye un control para modificar el umbral de clasificación, lo que permite observar cómo cambian las predicciones sin necesidad de volver a entrenar el modelo.

Entre los principales indicadores se incluyeron el total de interacciones, la tasa de escalamiento observada, el CSAT promedio y la cantidad de casos cuya probabilidad supera el umbral seleccionado.



Figura 9. Vista general del dashboard interactivo desarrollado con Dash y Plotly.

Visualizaciones e interacción

El dashboard integra diferentes visualizaciones diseñadas para complementar la interpretación de los modelos. Entre ellas se encuentra la tasa de escalamiento por canal, la distribución de probabilidades estimadas, la matriz de confusión, la comparación entre modelos y la importancia de variables.

La matriz de confusión se actualiza de acuerdo con el umbral seleccionado, mientras que la distribución de probabilidades permite observar la concentración de los valores estimados para los casos escalados y no escalados. De igual forma, la comparación de modelos permite contrastar métricas como ROC-AUC y F1-score.

También se incorporó una tabla con las interacciones que presentan las mayores probabilidades estimadas de escalamiento. Esta tabla puede filtrarse y ordenarse, permitiendo revisar de forma más detallada los registros de mayor interés dentro del conjunto de prueba.

La guía del proyecto establece que los callbacks deben permitir actualizar filtros, KPI, gráficos, narrativa y tabla, y que el cambio de umbral debe recalcular las métricas sin reentrenar el modelo.



Figura 10. Actualización de indicadores mediante filtros interactivos.

Interacciones con mayor probabilidad de escalamiento

ID	Canal	Tipo de cliente	Tipo de caso	Sentimiento	CSAT	AHT	Probabilidad
 filter data...							
1938	Email	Advertiser	Ad Billing	Negative	5	761	0.2758
8327	Email	Advertiser	Ad Billing	Negative	5	507	0.2653
732	Email	Business Page	Account Access	Neutral	4	1028	0.2557
4365	Email	Advertiser	Ad Billing	Negative	5	711	0.2516
7769	Email	User	Account Access	Neutral	5	310	0.2505
8372	Email	Advertiser	General Support	Negative	3	282	0.2448
2490	Email	User	Page Management	Negative	4	935	0.2437
2068	Email	Advertiser	Ad Billing	Negative	3	461	0.2427
3076	Email	Business Page	Ad Billing	Negative	1	926	0.2409
7677	Email	Business Page	Account Access	Neutral	5	310	0.2368

« < 1 / 3 > »

Figura 11. Interacciones con mayor probabilidad estimada de escalamiento.

En conjunto, el dashboard permite visualizar de manera integrada los principales resultados obtenidos durante el proyecto y facilita la exploración del comportamiento del modelo. Sin embargo, debido a la capacidad discriminante limitada observada en las etapas anteriores, las visualizaciones deben interpretarse como un apoyo exploratorio y no como una herramienta para automatizar decisiones operativas.

Capítulo VII

Limitaciones y oportunidades de mejora

Los resultados obtenidos muestran que, aunque se probaron diferentes técnicas de preprocesamiento, balanceo, transformación de variables, optimización de hiperparámetros y modelos lineales y no lineales, la capacidad predictiva se mantuvo limitada.

Una de las principales dificultades fue la baja separación entre las probabilidades estimadas para las interacciones escaladas y no escaladas. Esto se reflejó en valores de ROC-AUC cercanos a 0.50 y en un desempeño reducido para la identificación de la clase positiva.

También se observó que algunas métricas podían generar una interpretación engañosa si se analizaban de forma aislada. Por ejemplo, la accuracy de algunos modelos fue cercana al 80%, pero esto se debía principalmente al predominio de la clase no escalada. Por esta razón, fue necesario complementar el análisis con precision, recall, F1-score y ROC-AUC.

Otra limitación importante está relacionada con las variables disponibles. Aunque el dataset incluye información operativa como canal, tipo de cliente, tipo de caso, AHT, CSAT, FCR y sentimiento, estas variables no fueron suficientes para diferenciar de forma clara los casos escalados. Esto sugiere que podrían existir otros factores relevantes que no están representados en el conjunto de datos.

Como oportunidad de mejora, un trabajo futuro podría incorporar nuevas variables relacionadas con el historial del cliente, experiencia del agente, complejidad del caso, cantidad de contactos previos, motivo específico de escalamiento o tiempo transcurrido antes de la

resolución. También sería posible evaluar otros algoritmos de clasificación y técnicas más avanzadas de selección de variables.

Otra mejora metodológica sería separar de forma más estricta los procesos de selección de modelo y evaluación final. La guía del proyecto señala que una evaluación más rigurosa debería utilizar validación cruzada o un conjunto de validación para seleccionar el modelo y reservar el conjunto de prueba únicamente para la evaluación final.

Finalmente, el dashboard podría ampliarse en trabajos posteriores con nuevas visualizaciones, análisis temporal y métricas adicionales. Sin embargo, cualquier ampliación debería mantener la misma precaución en la interpretación de los resultados y evitar presentar el modelo como una herramienta confiable para automatizar decisiones operativas mientras su capacidad discriminante siga siendo reducida.

Capítulo VIII

Conclusiones

El desarrollo del proyecto permitió analizar de forma progresiva un problema de clasificación aplicado a interacciones de servicio al cliente, tomando como objetivo la predicción del escalamiento de los casos.

A lo largo del proceso se evaluaron diferentes alternativas, comenzando con una regresión logística sencilla y avanzando hacia modelos con más variables, balanceo de clases, transformación logarítmica, ajuste de hiperparámetros y finalmente un modelo de bosque aleatorio. Esta evolución permitió comprobar que una mejora en la complejidad del modelo no necesariamente se traduce en una mejora importante en la capacidad predictiva.

Los resultados mostraron que el bosque aleatorio obtuvo el mayor ROC-AUC entre los modelos evaluados, con un valor cercano a 0.51. Sin embargo, este resultado sigue siendo muy próximo a un comportamiento aleatorio, por lo que la capacidad para diferenciar entre casos escalados y no escalados es limitada.

También se evidenció que la accuracy no debe analizarse de manera aislada cuando existe desbalance entre clases. Algunos modelos alcanzaron valores cercanos al 80 %, pero no lograban identificar correctamente los casos escalados. Por esta razón, fue necesario complementar el análisis con métricas como precision, recall, F1-score y ROC-AUC.

Otro hallazgo importante fue que las probabilidades estimadas para ambas clases presentan un alto nivel de solapamiento. Esto sugiere que las variables disponibles en el dataset

no contienen suficiente información para separar de manera clara las interacciones escaladas de las no escaladas.

El dashboard desarrollado con Dash y Plotly permitió integrar los principales resultados del proyecto en una herramienta interactiva. A través de filtros, indicadores, gráficos, comparación de modelos, matriz de confusión y modificación del umbral, fue posible explorar de una manera más visual el comportamiento de los datos y de las predicciones.

En conclusión, el proyecto cumplió con el objetivo de desarrollar, comparar y analizar diferentes modelos de clasificación, además de presentar los resultados mediante un dashboard interactivo. Aunque no se obtuvo un modelo con alta capacidad predictiva, el proceso permitió identificar las limitaciones de los datos y establecer oportunidades claras de mejora para futuros trabajos.

Como trabajo posterior, sería recomendable incorporar nuevas variables relacionadas con el historial del cliente, experiencia del agente, cantidad de contactos previos, complejidad del caso o motivos específicos de escalamiento. La inclusión de información adicional podría aportar una señal predictiva más clara y mejorar el desempeño de futuros modelos.

referencias

Kohavi, R., Longbotham, R., Sommerfield, D., & Henne, R. M. (2009). Controlled experiments on the web: Survey and practical guide. *Data Mining and Knowledge Discovery*, 18, 140–181.
<https://doi.org/10.1007/s10618-008-0114-1>

Oehlert, G. W. (2010). *A first course in design and analysis of experiments*. University of Minnesota. <https://users.stat.umn.edu/~gary/Book.html>

Plotly Technologies Inc. (2023). *Dash documentation & user guides*. <https://dash.plotly.com/>

The Turing Way Community. (2021). *Zero to Binder. The Turing Way*.
<https://the-turing-way.netlify.app/communication/binder/zero-to-binder.html>

También te recomiendo agregar estas dos porque realmente utilizamos estas herramientas durante el desarrollo:

Pandas Development Team. (2024). *pandas documentation*. <https://pandas.pydata.org/docs/>

Scikit-learn Developers. (2024). *scikit-learn: Machine learning in Python*.
<https://scikit-learn.org/stable/>